CXR-LT 2024 — Báo cáo tiến độ

Kiến trúc, các hướng nghiên cứu, và khoảng cách tới mục tiêu

Nhóm CXR × EHR

10 tháng 9, 2026

Chỉ số hiện tại (test)	**0.2625**	macro-mAP, 40 nhãn, 78,946 ảnh
Nhà vô địch (đội A)	0.281	CXR-LT 2024 Task 1
Khoảng cách	**0.0185**	tương đương hạng 7–8 / 17 đội

1 Kiến trúc hiện tại

1.1 Bài toán và dữ liệu

Phân loại **đa nhãn** 40 bệnh lý trên phim X-quang ngực, dữ liệu MIMIC-CXR theo thiết lập chính thức của thử thách CXR-LT 2024 (Lin et al., arXiv:2506.07984). Thiết lập của chúng ta khớp tuyệt đối với ban tổ chức, nên con số so sánh trực tiếp được với bảng xếp hạng.

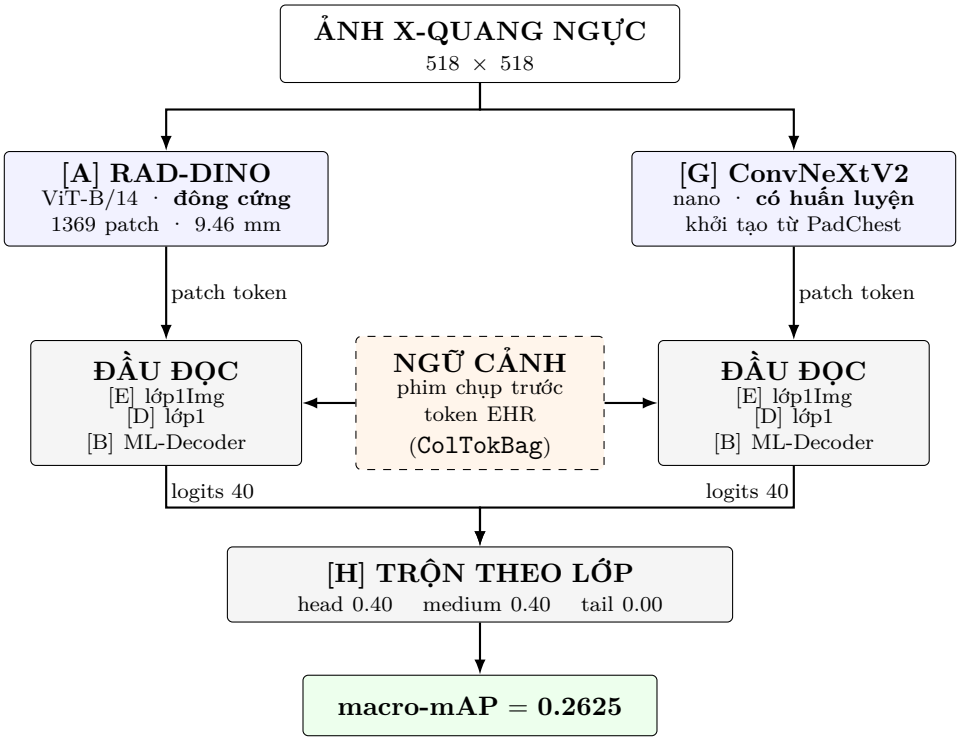
Thành phần	Mô tả	Số lượng
Train	chia theo bệnh nhân 70%	258,871 ảnh
Development	chia theo bệnh nhân 10%	39,293 ảnh
Test	chia theo bệnh nhân 20%	78,946 ảnh
Nhãn Task 1	đa nhãn, mất cân bằng nặng	40
Nhãn Task 3	zero-shot, **không được chạm**	5
Thước đo	macro-averaged AP; hoà thì xét mAUROC	—

Table 1: Thiết lập dữ liệu chính thức. Tuân thủ nhãn đã được kiểm: 5 nhãn zero-shot (`Bulla`, `Cardiomyopathy`, `Hilum`, `Osteopenia`, `Scoliosis`) không xuất hiện trong tập 40 nhãn của ta.

Phân tầng theo độ hiếm. Ban tổ chức chia theo *tỉ lệ hiện* trên train: head $> 10\%$, medium 1–10%, tail $< 1\%$, cho **9 / 15 / 16** nhãn. Thang riêng mà ta dùng trước ngày 08/09 chia theo *số ca* và cho 13 / 16 / 11 — mọi báo cáo lớp trước mốc đó dùng thang khác, cần đối chiếu cẩn thận.

1.2 Sơ đồ tổng thể

Hệ thống là **ensemble hai thành viên** có kiến trúc khác nhau, trộn theo lớp ở mức xác suất đầu ra.



Hai nhánh dùng **cùng một mã đầu đọc** nhưng là hai bản sao huấn luyện độc lập. Khác biệt thật nằm ở backbone: RAD-DINO *đông cứng* (chỉ 7.3M tham số đầu đọc được học), còn ConvNeXtV2 thì *huấn luyện cả backbone*. Thứ tự trong đầu đọc là `lớp1Img` (phim trước, không gian `D_CXR`) → `pin` → `lớp1` (token EHR) → ML-Decoder.

1.3 Các module

[A] Nhánh ảnh — backbone RAD-DINO

RAD-DINO ViT-B/14 ở độ phân giải 518^2, cho $37 \times 37 = 1369$ patch token (9,46 mm mỗi patch). Backbone được fine-tune một lần ở notebook `38a` (bản `a2_E3`) rồi **đông cứng hoàn toàn** cho mọi thí nghiệm sau. Việc mở băng thêm đã được thử và đóng lại (mục 2.2).

Hệ quả quan trọng của việc freeze: mọi seed của ta *dùng chung* 86M tham số giống hệt nhau, chỉ khác 7.3M tham số đầu đọc. Đây là lý do việc thêm seed chỉ cho +0.0008, và cũng là lý do hướng *ensemble backbone fine-tune độc lập* vẫn còn mở.

[B] ML-Decoder — đầu đọc đa nhãn

Mỗi bệnh lý được gán một vector truy vấn (Q) riêng. Bốn mươi vector này giữ nguyên từ lúc khởi tạo và không tham gia huấn luyện, nên toàn bộ việc học dồn vào phép chú ý và các lớp phía sau. Từng truy vấn quét khắp các patch của ảnh rồi gom về một biểu diễn dành riêng cho bệnh lý đó. Các truy vấn không trao đổi với nhau, nên bốn mươi bệnh lý được đọc song song và độc lập vì trong bài toán đa nhãn một phim có thể mang nhiều bệnh cùng lúc. Ở bước chấm điểm, mỗi bệnh lý dùng một vector trọng số của riêng nó trên đúng biểu diễn của nó, thay vì trải phẳng cả bốn mươi biểu diễn rồi đưa qua một lớp tuyến tính chung. Số tham số nhờ vậy giảm bốn mươi lần.

```
q  = class_query[40]                    # cố định, không học
kv = pin(patch)                         # 768 -> 512
kv = lớp1(kv, ein(etok))                # điều biến bởi EHR   [module D]
h  = XAttn(q, kv)                       # LayerNorm + FFN residual
logits = GroupFC(h)                     # [B, 40]
```

[C] Bộ mã hoá EHR — `ColTokBag`

Mỗi lần chụp đi kèm 257 con số: 217 đặc trưng lâm sàng (xét nghiệm, sinh hiệu, bệnh nền, các cờ vi sinh) và 40 điểm số do một mô hình cây chấm trước đó trên chính bảng EHR.

Thay vì nén cả 257 số thành một vector duy nhất, mỗi cột được cấp một token riêng. Danh tính token thuộc về *cột*: mỗi đặc trưng có một hướng cố định trong không gian 256 chiều, dùng chung cho mọi bệnh nhân. Giá trị của từng bệnh nhân chỉ quyết định *biên độ* — đặc trưng nào lệch xa mức bình thường thì token của nó mạnh lên. Nhờ vậy mô hình biết con số đang đọc là bạch cầu hay huyết áp, thay vì nhận một dãy số vô danh.

Mỗi lần chụp vì thế cho một chuỗi 259 token: 257 token cột, một token tóm tắt cả hàng, và một token vi sinh.

Vi sinh phải tách ra vì số chủng nuôi cấy được không cố định — nhiều ca không mọc chủng nào, một số ca mọc vài chủng, trung bình 1.7 chủng mỗi lần chụp. Đệm mọi ca về độ dài của ca nhiều nhất thì gần như toàn bộ ô là rỗng, nên thay vào đó các chủng của một ca được cộng gộp lại thành một token duy nhất, mỗi chủng có trọng số theo số lần nó mọc. Ba mươi cột vi sinh dạng phẳng đã bị loại khỏi bảng để không đếm hai lần.

[D] `lớp1` — điều kiện hoá bằng EHR ở mức patch

Đây là đóng góp kiến trúc trung tâm của dự án. Patch làm **query**, token EHR làm key/value — tức là EHR *điều biến biểu diễn ảnh* trước khi đầu đọc nhìn vào, chứ không phải nối vào sau.

- Phép chiếu `pr` khởi tạo bằng **không** ⇒ tại bước 0 mô hình đúng bằng bản ảnh thuần. Có assert kiểm điều này trước mỗi lượt chạy.
- `ln_a` chuẩn hoá *đầu vào* của phép chiếu. Thiếu nó, arm đối chứng ở `38d` sụp từ 0.2416 xuống 0.0681.

[E] `lớp1Img` — phim chụp trước ở mức patch

Phim trước của cùng bệnh nhân được đưa vào ở mức patch, chạy trong không gian `D_CXR` trước phép chiếu `pin`. **Không** trừ thẳng patch − prior vì hai phim không được đăng ký không gian (tư thế khác, độ hít vào khác). Zero-init *không* đủ để chặn một nhánh phụ lớn lên quá nhanh. AdamW cập nhật khoảng lr mỗi bước cho mỗi tham số bất kể gradient nhỏ thế nào, nên nhánh xuất phát từ 0 vẫn lớn *tuyến tính* theo bước. Đã sụp ba lần, luôn ở epoch 2–4 tức ngay sau đỉnh warmup. Bản hiện tại dùng hệ số **LayerScale** 10^{-4} có gradient thật, buộc mô hình phải *học* để lớn lên. Ảnh nào không có phim trước thì nhánh bị mask đi hẳn (28.7% số ảnh).

[F] Hàm mất mát — ASL

Asymmetric Loss với $\gamma_{\text{neg}} = 4$, $\gamma_{\text{pos}} = 0$, clip 0.05.

[G] Thành viên thứ hai — mạng tích chập

Thành viên thứ hai đổi backbone sang một mạng tích chập cỡ nhỏ, khởi tạo từ trọng số đã huấn luyện trước trên **PadChest** thay vì từ ImageNet. Phần đầu đọc giữ nguyên như pipeline chính: vẫn phim chụp trước ở mức patch, vẫn điều kiện hoá bằng EHR, vẫn bốn mươi truy vấn lớp. Chỉ backbone là khác, và đó là chủ ý.

Trước mỗi lượt chạy, trọng số khởi tạo được đối chiếu với bản ImageNet gốc. Nếu hai bên trùng khớp thì tệp PadChest đã không được nạp, và lượt chạy dừng lại thay vì âm thầm huấn luyện từ khởi tạo sai.

CNN yếu hơn pipeline với RAD-DINO trước đó (0.2463 so với 0.2663 trên val). Tuy nhiên hai kiến trúc khác nhau nên trong quá trình huấn luyện chúng cập nhật theo hàm mất mát theo những hướng khác nhau, và khi trộn lại thì sự đa dạng đó bổ sung cho nhau. Đó là lý do một thành viên yếu hơn vẫn làm cả ensemble mạnh lên.

[H] Trộn theo lớp

Ensemble 20 file `t1_prior_both` ⊕ 16 file `cnn_full`, trọng số theo lớp `head 0.40 | medium 0.40 | tail 0.00`, cổng 0.85. Trọng số được khoá từ trước và đã kiểm lại sau R2a: tỉ lệ $r = \mathrm{AP}_{\mathrm{cnn}}/\mathrm{AP}_{\mathrm{ống}}$ gần như không đổi (head 0.981 → 0.983, medium 0.921 → 0.923, tail 0.640 → 0.653), nên trọng số cũ vẫn đúng bối cảnh.

Tail nhận trọng số 0. Tạm thời giữ nguyên như vậy vì CNN quá yếu ở tail để đóng góp. Nghĩa là **16 nhãn tail hiện không nhận gì từ ensemble**, và đó là một trong những dư địa rõ nhất còn lại.

1.4 Hai arm huấn luyện

Mỗi lượt huấn luyện chạy song song hai arm dùng *chung một forward backbone*, nên arm đối chứng gần như miễn phí:

Arm	EHR	Phim trước	Vai trò
`mldec`	không	không	đối chứng ảnh thuần
`tpb`	có	có	pipeline chính (*t1_prior_both*)

Table 2: Hiệu số $G_{\mathrm{ctx}} =$ `tpb` − `mldec` đo trực tiếp đóng góp của ngữ cảnh EHR + phim trước, trong cùng một lượt chạy nên không có nhiễu giữa các lượt.

Siêu tham số chốt. 518^2 · batch $32 \times 8 = 256$ hiệu dụng · 10 epoch · LR 10^{-3} · WD 10^{-2} · warmup 5% · clip 5.0 · seed 42, 43. Thành viên CNN: batch $48 \times 6 = 288$, 8 epoch, LR 10^{-4}.

2 Các hướng đã đề ra: kết quả và trạng thái

2.1 Hướng đã hoàn thành và có lợi

	Hướng	Kết quả	Ghi chú
XONG	**R2a** — gộp lát chọn vào train (74% → 87% dữ liệu có nhãn)	**+0.0042** test	8/8 phép so lớp dương; CI95 [+0.0033, +0.0051], loại 0
XONG	Điều kiện hoá EHR ở mức patch (`lớp1`)	$G_{\mathrm{ctx}} \approx +0.0115$	đóng góp ngữ cảnh, đo trong cùng lượt
XONG	Phim trước ở mức patch (`lớp1Img`)	dương, nhỏ	LayerScale bắt buộc, nếu không sẽ sụp
XONG	Ensemble 2 kiến trúc, trộn theo lớp	**+0.0042**	cấu hình triển khai hiện tại

Chi tiết R2a. Lát chọn (39,086 ảnh) vốn là thước đo để chọn siêu tham số. Khi mọi lựa chọn đã khoá, nó hết vai trò và được thu hồi vào train.

2.2 Hướng đã ĐÓNG

Mỗi dòng dưới đây là một giả thuyết đã bị bác bỏ bằng phép đo, không phải bị bỏ vì hết thời gian. Ghi lại đầy đủ vì kết quả âm cũng là thông tin nghiên cứu.

Cấu hình	n file	macro	head	medium	tail
`53/r3` pipeline cũ	20	0.2641	0.4758	0.1942	0.1155
`64/r2a` pipeline R2a	20	**0.2663**	0.4775	0.1958	**0.1193**
`41e/r1` cnn cũ	16	0.2435	0.4667	0.1788	0.0739
`64b/r2a` cnn R2a	16	**0.2463**	0.4695	0.1808	**0.0779**

Table 3: Val, thang lớp *cũ* (13/16/11). pipeline +0.0022 macro và +0.0039 tail; CNN +0.0028 macro và +0.0040 tail. Cơ chế: thêm 17.8% dữ liệu là thêm 17.8% ca dương, mà nhãn hiếm nhất chỉ có khoảng 150 ca dương nên thêm vài chục ca là đáng kể; head thì đã bão hoà.

	Hướng	Bằng chứng đóng
ĐÓNG	Đưa EHR vào sâu trong backbone	Đo chênh lệch giữa nhánh có điều kiện hoá sâu và nhánh đối chứng chạy song song: chênh lệch **âm**, lặp lại ổn định qua nhiều seed. Đưa EHR vào sâu kém hơn đưa vào ở đầu đọc.
ĐÓNG	Mở khoá bốn khối trên cùng của backbone	Điểm giảm 0.007 đến 0.010. Hai seed cho cùng kết luận, và nhánh đối chứng chạy song song vẫn khoẻ, nên đây không phải sự cố của một lượt chạy.
ĐÓNG	Huấn luyện lại riêng tầng phân loại	Ý tưởng là tách tầng cuối ra học lại trên dữ liệu đã cân bằng. Đo ra thì tầng này **đã hội tụ**, không còn gì để tách.
ĐÓNG	Ghép đặc trưng đa tỉ lệ từ mạng tích chập	Trượt cổng. Nguyên nhân đo được ở `62`: tầng thứ ba gần như chỉ mang *một* chiều thông tin thực (hạng hiệu dụng 1.1 trên 320 kênh), nên 1024 khoá thêm vào gần như trùng nhau và chỉ làm loãng chú ý.
ĐÓNG	Tăng độ phân giải chỉ ở lúc suy luận	Ảnh vào lớn hơn nhưng đầu đọc vẫn là bản đã huấn luyện ở 518. Số lượng vùng ảnh thay đổi khiến đầu vào lệch khỏi phân phối lúc huấn luyện: -0.0028.
ĐÓNG	Thêm seed trên cùng một backbone đông cứng	+0.0008, dưới sàn nhiễu 0.0007. Điều này *không* đóng hướng huấn luyện lại backbone độc lập rồi mới trộn — đó là phép đo khác hẳn.
ĐÓNG	Hiện tượng co cụm biểu diễn lớp	Kiểm trực tiếp giả thuyết biểu diễn của mỗi lớp co về một điểm. Không quan sát thấy.
ĐÓNG	Trọng số trộn phụ thuộc chất lượng từng nhãn	**Tương quan giả do nhiễu dùng chung.** Đo hai đại lượng trên *cùng* một tập cho tương quan +0.598; đo trên hai tập *tách rời* thì tụt còn +0.136 với $p = 0.40$. Cả hai đại lượng đều chứa điểm của pipeline, nên nhiễu của nó tự sinh ra tương quan.
ĐÓNG	Dùng độ tương đồng giữa hai thành viên làm biến quyết định	Đại lượng này đo được rất ổn định, nhưng **không dự báo được gì**: tương quan của nó với mức cải thiện thực tế chỉ +0.017.
ĐÓNG	Bốn cách trộn rẻ, không cần GPU	Trung bình thứ hạng thay cho trung bình xác suất, quét lại trọng số theo lớp, cân theo chất lượng từng epoch, và thêm thành viên thứ ba. **Tất cả cho** +0.0000**.** Cấu hình đang dùng vẫn tốt nhất (0.2709); thêm thành viên thứ ba còn tụt xuống 0.2693.

	Hướng	Bằng chứng đóng
ĐÓNG	Cắt vùng nghi ngờ rồi phóng to	Vùng cắt trung bình chiếm **79% diện tích ảnh**, nên độ phóng đại thực chỉ 1.06 lần và kết quả +0.0003 không có ý nghĩa. Cắt hẹp hơn cũng không cứu được, vì dấu hiệu bệnh trải khắp lồng ngực chứ không gom vào một chỗ.
ĐÓNG	Định vị vùng mô hình đang nhìn	Che bớt ảnh, chỉ chừa lại số ít vùng mà mô hình chú ý nhiều nhất. Giữ 5% số vùng vẫn đạt 96–99% điểm gốc; giữ 20% thì nhóm nhãn hiếm còn *cao hơn* cả lượt dùng toàn ảnh. Mô hình không hề nhìn nhầm chỗ — và điều đó lấy đi luôn lý do tồn tại của hướng cắt vùng rồi phóng to.
ĐÓNG	Đưa cả pipeline lên độ phân giải 1022	Điểm chung giảm 0.0055, nhóm nhãn hiếm giảm 0.0138. Mọi nhãn thiệt hại nặng đều thuộc nhóm hiếm, mọi nhãn hưởng lợi đều thuộc nhóm trung bình.
ĐÓNG	Gắn lại nhãn bằng mô hình ngôn ngữ	Nhãn của tập test bẩn theo *đúng cùng một kiểu* với nhãn huấn luyện, và lỗi đến từ bộ phân tích văn bản nên mang tính hệ thống chứ không ngẫu nhiên. Dạy mô hình đoán đúng bệnh thật sẽ kéo nó ra *xa* thước đo đang được chấm.

ViT thua ở độ phân giải cao. Bốn mươi class query phải học phân bố attention trên 5,329 Key thay vì 1,369 — gấp 3.9 lần. Nhãn có 26,000 ca dương thì học được; nhãn có 129 ca dương thì **pha loãng thống kê**. Chỉ dấu phụ: G_{ctx} tụt từ +0.0115 xuống +0.0029.

	64 @518	68 @1022	chênh
macro	0.2645	0.2590	−0.0055
head	0.5593	0.5545	−0.0048
medium	0.2227	0.2256	**+0.0029**
tail	0.1379	0.1241	**−0.0138**

Table 5: Nhãn hại nặng nhất: `Clavicle Fracture` −0.0916 (prevalence 0.065%). Nhãn lợi nhất: `Granuloma` +0.0484 (1.145%).

Khi chạy thí nghiệm về độ phân giải thì mới chỉ chạy 3 epoch, 1 seed, $E = 6$. Đây là phép *sàng*, không phải phép *đóng* tuyệt đối. Phát biểu an toàn: *ở cùng mức chi phí, ViT không đổi được độ phân giải thành lợi ích.* Việc CNN có làm được hay không là câu hỏi riêng, đang chờ `nb68b` trả lời.

2.3 Hướng còn MỞ

	Hướng
MỞ	`nb68b` — ConvNeXtV2 @1022
MỞ	**Weighted asymmetric loss**
MỞ	K-fold + fine-tune backbone theo từng fold
MỞ	Sinh ảnh diffusion cho nhãn hiếm